Homework2:NBC

姓名: 刘敏 学号: 201814820

● 实验要求:

实现朴素贝叶斯分类器,测试其在 20 Newsgroups 数据集上的效果

• 实验过程:

朴素贝叶斯算法实现:每个测试样本属于某个类的概率 = 某个类中出现样本中单词的概率的乘积(类条件概率)*某个类出现的概率(先验概率)

即 p(cate|doc)=p(**word**|cate)*p(cate)

具体计算类条件概率和先验概率时, 朴素贝叶斯分类有两种模型:

① 多元分布模型:以单词为粒度,不仅仅计算特征词出现/不出现,还要计算出现的次数

类条件概率 p(word|cate)=(类 cate 中单词 word 出现在所有文档中的次数之和+1)/(类 cate 中单词总数+训练样本中不重复的特征词总数)
先验概率 p(cate)=类 cate 中单词总数/训练样本中特征词总数

② 伯努利模型: 以文件为粒度

类条件概率 p(word|cate)=(类 cate 中出现 word 的文件总数 +1)/(类 cate 中文件总数+2)

先验概率 p(cate)=类 cate 中文件总数/整个训练样本中文件总数为了实现更好的分类结果,我们将采取细粒度也就是**以单词为粒度**的多元分布模型构造朴素贝叶斯分类器,其实现过程如下所述:

1. 由 getCateWordsFre(data_path)函数统计训练样本中每个类中单词总数以及每个单词出现的次数,分别存储在字典 cateWordsNum 和 cateWordsFre 中。

- 其中, cateWordsNum 中 < key, value > 对表示 < 类别, 单词总数 > ; cateWordsFre 中 < key, value > 对表示的是 < 类别_单词, 该单词出现的次数 >
- 2. computeCateProb(trainCate,testFilesWords,cateWordsNum,trainTotalNum, cateWordsFre)方法则实现了类条件概率以及先验概率的计算,从而得到p(cate|doc)。需要注意的是计算概率时用到了平滑技术以及取对数的操作
- 3. 然后使用 NBProcess(train_path, test_path, classifyResultByNB)函数对测试 样本进行分类,也就是将该文档在某类别下具有最高概率值的类别作为其最终 分类结果,并将结果写入文件 classifyResultByNB.txt 中,用于统计准确率
- 4. 最后就是计算 NBC 模型的准确率了,由函数 computeAcc(rightCate, resultCate)实现,这里用到测试样本中文档本身的类别,通过将其与预测类别进行比较,得到分类正确的数目,以计算准确率。

实验结果:

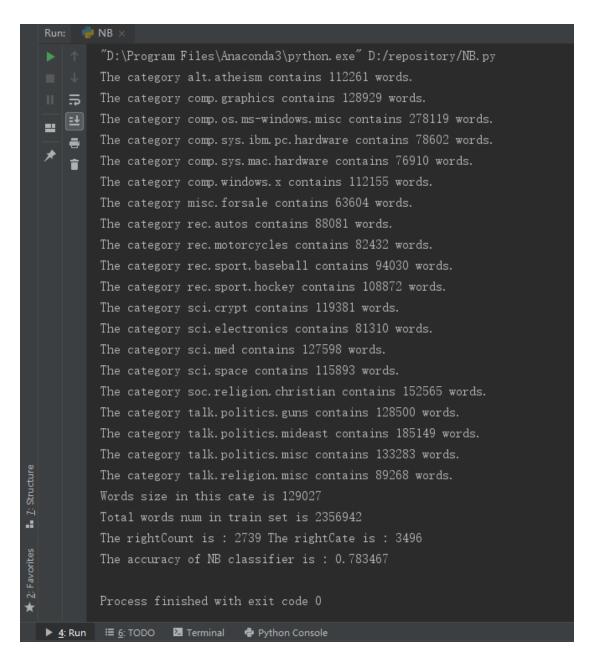
部分测试样本自身类别 from classifyRightCateO.txt

Preproces	s.py ×	ૄ createDict.py →	× 🐉 NB.py ×	
4	51121	alt.atheism		
5	51122	alt.atheism		
6	51123	alt.atheism		
7	51124	alt.atheism		
8	51125	alt.atheism		
9	51126	alt.atheism		
10	51127	alt.atheism		
11	51128	alt.atheism		
12	51130	alt.atheism		
13	51131	alt.atheism		
14	51132	alt.atheism		
15	51133	alt.atheism		
16	51134	alt.atheism		
17	51135	alt.atheism		
18	51136	alt.atheism		
19	51139	alt.atheism		
20	51140	alt.atheism		
21	51141	alt.atheism		
22	51142	alt.atheism		
23	51143	alt.atheism		
24	51144	alt.atheism		
25	51145	alt.atheism		
26	51146	alt.atheism		
27	51147	alt.atheism		
28	51148	alt.atheism		
29	51149	alt.atheism		
30		alt.atheism		
31	51151	alt.atheism		
32		alt.atheism		
33		alt.atheism		
34		alt.atheism		
35		alt.atheism		
36		alt.atheism		
37		alt.atheism		
38	51158	alt.atheism		

部分测试样本预测类别 from classifyResultByNB.txt

```
🛵 createDict.py >
                                  🐔 NB.py 🗦
                                              classifyRightCate0.txt ×
                                                                   🛔 classifyResultByNB.txt
💤 Preprocess.py >
           51119 soc. religion. christian
          51121 talk.politics.misc
          51122 alt. atheism
          51124 alt. atheism
          51125 alt. atheism
          51127 alt. atheism
          51128 alt. atheism
          51130 alt.atheism
          51131 alt. atheism
          51133 alt. atheism
          51134 alt. atheism
          51139 alt. atheism
          51140 talk.politics.guns
          51142 alt. atheism
          51143 alt. atheism
          51144 talk.politics.guns
          51145 talk.politics.guns
          51146 alt.atheism
          51147 alt. atheism
          51149 alt. atheism
          51150 alt. atheism
           51153 alt. atheism
           51154 alt. atheism
```

实验运行结果展示: (最终分类准确率为 0.78)



总结: 朴素贝叶斯算法比较简单, 主要是在多元分布模型和伯努利模型的选取上, 我选择了多元分布模型, 就是以单词为粒度计算分类概率, 相较于以文件为粒度的伯努利模型, 本模型具有更细层次的粒度, 所以我认为其分类效果应该是优于伯努利模型的, 只是没有进行实验验证, 之后有时间会试一下。