Homework3: Clustering with sklearn

姓名: 刘敏 学号: 201814820

● 实验要求:

测试 sklearn 中 8 种聚类算法在 tweets 数据集上的聚类效果; 使用 NMI(Normalized Mutual Information)作为评价指标。

• 实验过程:

聚类算法实现:

- 1. 首先读取 json 文件,将文档信息存入 texts 中,将文档类别标签存入 labels 中
- 2. 使用 sklearn.feature_extraction.text 中的 CountVectorizer()方法将文档中的 单词转换为词频矩阵,再通过 TfidfTransformer()方法计算每个单词的 tfidf 权 重,最后将计算得到的 tfidf 权重值数组化,即元素 weight[i][j]表示 j 词在 i 类 文本中的 tf-idf 权重
- 对所要求实现的 8 个聚类算法,从 sklearn 中导入对应的的聚类算法 KMeans,
 AffinityPropagation,
 AgglomerativeClustering, DBSCAN, GaussianMixture
- 4. 每个聚类算法实现都是先调用 fit()方法进行适配,再预测训练数据标签,最后使用 NMI 指标评价聚类效果

• 实验结果:

Tweets.txt 中数据格式如下:

```
["text": "brain fluid buildup delay giffords rehab". "cluster": 37)

["text": "brain fluid buildup delay giffords rehab". "cluster": 14]

["text": "ma appoints chairman tampa convention effort visit tampa republican mati tampa fl", "cluster": 100)

["text": "ghagho camp futile cut ivory coast economy", "cluster": 110)

["text": "chinese president lost translation powerful leader meet expect tran", "cluster": 61]

["text": "chinese president lost translation powerful leader meet expect tran", "cluster": 60)

["text": "postest reform start yenen hundred anti government protester gathered sanam", "cluster": 79)

["text": "protest reform start yenen hundred anti government protester gathered sanam", "cluster": 79)

["text": "stuxmet lead chernobyl russian", "cluster": 83]

["text": "supone share smartphones phone", "cluster": 81]

["text": "feed epic sci fi car ad kia optimum super bowl commercial video trendhunter supe", "cluster": 99)

["text": "super bowl commercial", "cluster": 99)

["text": "super bowl commercial", "cluster": 72)

["text": "super bowl commercial", "cluster": 66)

["text": "stuxnel plearman join current tw report", "cluster": 30)

["text": "stutic plearman join current tw report", "cluster": 30)

["text": "sundance day strange celebrity encounter steve carell elijah wood full day sundanc", "cluster": 96)

["text": "sandance day strange celebrity encounter steve carell elijah wood full day sundanc", "cluster": 96)

["text": "finished watching black swan twisted mental strain take embrace role natalie portman incredible", "cluster": 101)

["text": "hot air breaking rahm ballot text lt state totally corrupt", "cluster": 29)

["text": "hot air breaking rahm ballot text lt state totally corrupt", "cluster": 99)

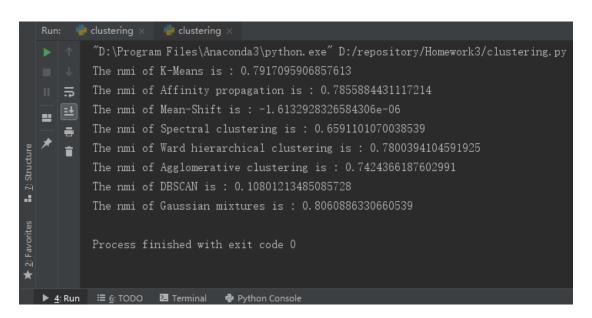
["text": "hot air breaking rahm ballot text lt state totally corrupt", "cluster": 99)

["text": "hot air breaking rahm ballot text lt state totally corrupt", "cluster": 101)

["text": "hot air breaking rahm ballot text lt state totally corrupt", "cluster": 79)

["text": "hot air breaking and
```

实验运行结果展示:



总结:通过几节课的学习,已经对以上几种聚类算法有了大致的了解,加上本次实验可以直接使用 sklearn 中已有的聚类算法实现,所以实验难度降低不少,首先要做的就是对数据的预处理,由于之前做 KNN 的时候已经做过构建 VSM 的相关实

验,所以这次就使用 sklearn 中用于文本特征提取的现有方法直接计算得到每个单词的 tfidf 权重,所以本次工作量不大。但是最终结果有点瑕疵,就是不知道什么原因,在对聚类算法 Mean-shift 计算 NMI 值的时候出现为负的情况,这是我始料未及的,然而还没有找到出错点,会继续更改。